
Die visuelle Sprache wissenschaftlicher Preprints

Caption-basierte Klassifikation von Abbildungen auf bioRxiv

Projektbericht im Projektmodul DIS22

an der Fakultät für Informations- und Kommunikationswissenschaften
der Technischen Hochschule Köln

vorgelegt von:	Ismail Salkovic, Talha Arslan, Necip Sedat Palaoglu
eingereicht bei:	Prof. Dr. Philipp Schaer
Zweitprüfer:	Fabian Haak
Projektgruppe:	A-Team

Köln, August 2026

Inhalt

Die visuelle Sprache wissenschaftlicher Preprints	1
Inhalt	II
1 Einleitung und Motivation	1
1.1 Relevanz und Ausgangslage.....	1
1.2 Stand der Forschung.....	1
1.3 Forschungsfragen	2
2 Daten und Methodik	2
2.1 Datengrundlage	2
2.2 Manuelle Annotation	3
2.3 Datenaufteilung und Vermeidung von Data Leakage	3
2.4 Klassifikationsverfahren	4
2.5 Vergleichsmaßstäbe	4
2.6 Evaluationsdesign und Metriken	5
3 Ergebnisse	5
3.1 Struktur des annotierten Datensatzes	5
3.2 Vergleich der Verfahren	7
3.3 Ergebnisse pro Klasse	8
3.4 Einfluss des Multi-Label-Trainings.....	8
3.5 Kombination von Regelwerk und Klassifikator.....	9
3.6 Sprachliche Signatur der Abbildungstypen.....	9
3.7 Fehleranalyse	10
3.8 Anwendung auf einen Gesamtkorpus	10
4 Diskussion und Fazit.....	12
4.1 Beantwortung der Forschungsfragen	12
4.2 Vergleich mit dem bildbasierten Vorgehen	12
4.3 Kritische Reflexion	14
4.4 Ausblick	15
5 Reproduzierbarkeit und Quellcode.....	15
Literaturverzeichnis	16
Abbildungsverzeichnis	17
Tabellenverzeichnis	18
Beitragsmatrix	19

1 Einleitung und Motivation

1.1 Relevanz und Ausgangslage

Wissenschaftliche Erkenntnisse werden nicht allein über Fließtext vermittelt. Diagramme, Messkurven, schematische Darstellungen und Mikroskopieaufnahmen tragen einen erheblichen Teil der Argumentation und verdichten Ergebnisse auf eine Weise, die Text allein nicht leisten kann. In der Bibliometrie und Szientometrie stehen dennoch überwiegend Zitationen und Volltexte im Mittelpunkt, während der visuelle Anteil einer Publikation kaum systematisch erfasst wird.

Dass sich ein genauerer Blick auf diesen blinden Fleck lohnt, haben Lee et al. (2016) gezeigt. Typ und Menge visueller Information korrelieren mit dem wissenschaftlichen Einfluss einer Arbeit, und die Zusammensetzung der Abbildungstypen unterscheidet sich deutlich zwischen den Fachgebieten. Solche Analysen setzen allerdings voraus, dass Abbildungen im großen Maßstab automatisch nach ihrem funktionalen Typ klassifiziert werden können. Genau an dieser Stelle setzt das vorliegende Projekt an.

Der etablierte Weg dorthin ist bildbasiert. Ein Modell lernt dabei unmittelbar aus den Pixeln, um welche Art von Abbildung es sich handelt. Dieses Vorgehen ist leistungsfähig, setzt jedoch voraus, dass die Bilddateien überhaupt vorliegen und in einem rechenintensiven Schritt verarbeitet werden. In vielen bibliometrischen Datenbeständen finden sich aber nur strukturierte Metadaten, die zwar die Bildunterschrift enthalten, nicht jedoch die Abbildung selbst. Für solche Fälle wäre ein textbasiertes Verfahren die einzige praktikable Option, und es ließe sich zugleich mit sehr geringem Rechenaufwand auf ganze Korpora anwenden.

1.2 Stand der Forschung

Die zentrale Vorarbeit für dieses Projekt ist Viziometrics von Lee et al. (2016). Die Autoren untersuchen rund 4,8 Millionen Abbildungen aus PubMed Central, wobei zusammengesetzte Abbildungen zunächst in einzelne Abbildungen zerlegt werden. Anschließend werden die Abbildungen den fünf Kategorien Plot, Diagram, Photo, Equation und Table zugeordnet. Untersucht wird, wie sich die daraus resultierenden Verteilungsmuster zum wissenschaftlichen Einfluss der Arbeiten verhalten. Technisch beruht das Verfahren auf klassischen Bildmerkmalen, die einem Support-Vector-Machine-Klassifikator zugeführt werden. Auf einem Testset mit fünf Kategorien berichten die Autoren eine Klassifikationsgenauigkeit von etwa 91 Prozent.

Für das vorliegende Projekt ist diese Arbeit in zweifacher Hinsicht maßgeblich. Zum einen übernehmen wir das dort entwickelte Kategoriensystem, um an eine etablierte Taxonomie anzuschließen, statt eine eigene zu definieren. Zum anderen dient das bildbasierte Vorgehen als methodischer Kontrast. Da Lee et al. ausschließlich Bilddaten verwenden, bleibt die Frage offen, wie viel Information über den visuellen Typ bereits im begleitenden Text enthalten ist. Diese Lücke adressiert der hier beschriebene caption-basierte Ansatz.

Die Kategorien Equation und Table wurden bewusst ausgeklammert. Beide besitzen im zugrunde liegenden Datenformat eine abweichende Struktur, werden dort teils in eigenen Feldern geführt und verfügen häufig über keine oder nur formelhafte Bildunterschriften. Eine gemeinsame Behandlung mit den drei bildhaften Typen hätte die Vergleichbarkeit der Ergebnisse beeinträchtigt.

1.3 Forschungsfragen

Aus der beschriebenen Ausgangslage ergeben sich drei Forschungsfragen, an denen sich die weitere Darstellung orientiert:

FF1: Lässt sich der Typ einer wissenschaftlichen Abbildung allein aus dem Text ihrer Bildunterschrift bestimmen, und welche Güte erreicht ein solches Verfahren?

FF2: Welchen Mehrwert bietet ein trainierter Klassifikator gegenüber einer regelbasierten Schlüsselwortsuche, deren Begriffe aus der Literatur und aus den Trainingsdaten abgeleitet sind?

FF3: Wie unterscheiden sich die drei Abbildungstypen in ihrer sprachlichen Kodierung, und wo stößt ein rein textbasiertes Verfahren an seine Grenzen?

Ergänzend greift der Bericht zwei Punkte auf, die in der Abschlusspräsentation offengeblieben sind. Zum einen wird die caption-basierte Klassifikation dem bildbasierten Vorgehen von Lee et al. ausführlich gegenübergestellt, was Gegenstand von Abschnitt 4.2 ist. Zum anderen wertet Abschnitt 3.1 die Struktur der annotierten Daten quantitativ aus, insbesondere den Anteil der Mehrfachzuweisungen und die Verteilung der drei Klassen.

2 Daten und Methodik

2.1 Datengrundlage

Grundlage der Arbeit ist ein Stichproben-Datensatz aus Preprints der Plattform bioRxiv, der allen Projektgruppen des Moduls zur Verfügung gestellt wurde. Die Preprints liegen als strukturierte JSON-Dateien vor. Für jede Abbildung enthalten sie die Bildunterschrift, die Seitenzahl und die Koordinaten des zugehörigen Bereichs im PDF sowie Metadaten wie die Fachrichtung und den DOI. Der Datensatz umfasst 4.019 Abbildungen. Bei 1.921 davon besteht das Caption-Feld lediglich aus einer Kurzbezeichnung wie „Fig. 3“ ohne inhaltlichen Text. Da ein textbasiertes Verfahren aus solchen Einträgen keine Information gewinnen kann, wurden sie von der Verarbeitung ausgeschlossen und im Korpuslauf separat ausgewiesen.

Die verbleibenden Bildunterschriften sind vergleichsweise umfangreich. Im Trainingsdatensatz beträgt die mediane Länge 86 Wörter bei einem Mittelwert von 100,5 Wörtern, die Spannweite reicht von 5 bis 476 Wörtern. Diese Länge ist eine wesentliche Voraussetzung des Ansatzes, da sie hinreichend viele inhaltliche Begriffe für eine Merkmalsextraktion bereitstellt.

2.2 Manuelle Annotation

Für Training und Evaluation wurde eine eigene Ground Truth erstellt. In einem ersten Durchgang annotierten wir 1.000 Abbildungen, die zu etwa gleichen Teilen auf die drei Teammitglieder verteilt waren, für die Evaluation kamen anschließend rund 300 weitere hinzu. Nach Ausschluss der Fälle, die als unklar markiert waren, keiner der drei Kategorien zugeordnet werden konnten oder über keine verwertbare Bildunterschrift verfügten, verbleiben 1.254 Abbildungen. Diese Menge wurde nicht entlang der beiden Annotationsdurchgänge übernommen, sondern preprint-rein neu aufgeteilt (Abschnitt 2.3). Die verwendeten 943 Trainings- und 311 Evaluationsabbildungen entsprechen daher nicht deckungsgleich den ursprünglichen Stapeln. Eine methodisch zentrale Festlegung betrifft die Grundlage der Annotation. Vergeben wurden die Labels ausschließlich anhand des Bildes, das über die JSON-Koordinaten aus dem Original-PDF gerendert wurde, nicht anhand der Bildunterschrift. Wäre die Caption zur Labelvergabe herangezogen worden, hätte ein Zirkelschluss gedroht. Das Modell wäre auf die eigene Lesart der Annotierenden trainiert worden, und die gemessene Güte hätte nicht mehr ausgesagt, wie viel Information tatsächlich im Text steckt. Aus demselben Grund war der eigene Stichproben-Datensatz unverzichtbar, da nur dort die zugehörigen PDF-Dateien vorlagen.

Umgesetzt wurde die Annotation mit einem eigens entwickelten Werkzeug auf Basis von Tkinter und PyMuPDF. Es schneidet die jeweilige Abbildung anhand der hinterlegten Koordinaten passgenau aus dem PDF aus, zeigt sie an und erlaubt eine reine Tastaturbedienung über Hotkeys für die drei Einzeltypen sowie die Mehrfachzuweisungen. Unsichere Fälle konnten gesondert markiert werden. Da eine Abbildung mehrere Panels unterschiedlichen Typs enthalten kann, wurde durchgehend im Multi-Label-Schema annotiert. Jeder zutreffende Typ wird vergeben, die Zuordnung ist also nicht exklusiv.

2.3 Datenaufteilung und Vermeidung von Data Leakage

Die annotierten Daten wurden in ein Trainingsset mit 943 und ein Evaluationsset mit 311 Abbildungen aufgeteilt. Die Aufteilung erfolgte nicht zufällig auf Ebene einzelner Abbildungen, sondern gruppiert auf Ebene der Preprints. Dahinter steht ein subtiler, aber folgenreicher Effekt. Abbildungen desselben Preprints teilen Thema, Terminologie und Schreibstil ihrer Autorinnen und Autoren. Lägen Abbildungen eines Papers gleichzeitig im Trainings- und im Evaluationsset, würde das Modell im Test teilweise bereits bekanntes Vokabular wiedererkennen und besser erscheinen, als es auf tatsächlich unbekannten Publikationen wäre.

Technisch wurde dies über eine gruppierte Aufteilung nach der Quelldatei realisiert. Das Evaluationsset umfasst 73 Preprints, die im Training nicht vorkommen, die Überschneidung beträgt null Preprints. Im Mittel steuert jedes Preprint rund vier Abbildungen bei, und eben diese Gruppenstruktur macht die preprint-reine Trennung notwendig. Alle im Folgenden berichteten Kennzahlen beziehen sich auf dieses unabhängige Gold-Set.

2.4 Klassifikationsverfahren

Das Klassifikationsverfahren besteht aus zwei Stufen. In der ersten Stufe wird jede Bildunterschrift über eine TF-IDF-Gewichtung in einen numerischen Merkmalsvektor überführt. Die Gewichtung verbindet die Häufigkeit eines Begriffs innerhalb der jeweiligen Caption mit seiner Seltenheit über den gesamten Bestand. Begriffe, die in nahezu jeder Bildunterschrift auftreten, erhalten dadurch ein geringes Gewicht, während inhaltlich unterscheidungskräftige Ausdrücke stark gewichtet werden. Berücksichtigt werden Uni- und Bigramme, da Wortpaare wie „scale bar“ oder „bar chart“ deutlich eindeutiger sind als ihre Einzelbestandteile. Begriffe, die nur in einem einzigen Dokument vorkommen, werden ausgeschlossen.

In der zweiten Stufe arbeiten drei voneinander unabhängige logistische Regressionen im One-vs-Rest-Schema, je eine für Plot, Diagram und Photo. Jedes Modell lernt für die Begriffe des Vokabulars Gewichte, die angeben, wie stark ein Ausdruck für oder gegen die jeweilige Klasse spricht, summiert diese Gewichte für eine neue Caption auf und überführt das Ergebnis in eine Wahrscheinlichkeit. Da die drei Modelle getrennt entscheiden, sind Mehrfachzuordnungen möglich. Diese Anforderung ergibt sich unmittelbar aus der Multi-Label-Struktur der Daten. Weil die Klasse Photo deutlich seltener auftritt als Plot, werden Fehler bei unterrepräsentierten Klassen über eine ausgleichende Klassengewichtung stärker gewichtet. Ohne diese Maßnahme wäre die Strategie, Photo grundsätzlich zu verneinen, rein rechnerisch attraktiv, inhaltlich aber wertlos.

Die Entscheidung für ein lineares und gut interpretierbares Modell erfolgte bewusst. Bei einer Datenbasis von rund 900 Trainingsbeispielen ist ein komplexeres Verfahren nicht angezeigt, und die gelernten Wortgewichte lassen sich unmittelbar inspizieren, was für die inhaltliche Auswertung in Abschnitt 3.6 wesentlich ist.

2.5 Vergleichsmaßstäbe

Ein einzelner Kennwert lässt sich ohne Bezugspunkt kaum einordnen. Ob ein Macro-F1 von 0,70 gut oder schwach ist, hängt davon ab, was einfachere Verfahren auf denselben Daten erreichen. Aus diesem Grund wurden zwei Vergleichsmaßstäbe implementiert.

Die Mehrheitsklassen-Baseline sagt unabhängig vom Eingabetext stets die häufigste Klasse voraus. Sie lernt nichts und markiert damit den Nullpunkt der Skala. Ihr Nutzen liegt in zwei diagnostischen Funktionen. Sie belegt, dass ein Modell überhaupt substantielle Information nutzt, und sie zeigt auf, wie stark eine ungleiche Klassenverteilung einfache Metriken verzerrt.

Die zweite Baseline ist eine regelbasierte Schlüsselwortsuche. Enthält eine Caption einen Begriff aus der Wortliste einer Klasse, wird das entsprechende Label gesetzt. Da eine frei zusammengestellte Wortliste methodisch angreifbar wäre, wurde sie aus zwei belegbaren Quellen abgeleitet. Den Kern bilden die Beispielbegriffe, mit denen Lee et al. ihre Kategorien definieren, etwa „bar chart“ und „scatter plot“ für Plot oder „schematic“ und „flow chart“ für Diagram. Ergänzt wurden diese um Begriffe, die über eine TF-IDF-

Analyse ausschließlich auf dem Trainingsdatensatz als besonders trennscharf identifiziert wurden. Das Evaluationsset blieb bei dieser Herleitung unberührt.

Eine Vorstufe, die allein die wörtlichen Beispielbegriffe aus Lee et al. verwendete, erreichte lediglich einen Macro-F1 von 0,394. Der Grund dafür liegt in der Beschaffenheit der Captions. Bildunterschriften benennen den Diagrammtyp nur selten explizit, sondern beschreiben den dargestellten Sachverhalt. Ausdrücke wie „mean values with error bars“ sind für einen Plot weit typischer als das Wort „bar chart“. Erst die datengetriebene Ergänzung hebt die Baseline auf ein Niveau, das als ernsthafter Vergleichsmaßstab taugt. Der Unterschied zum Klassifikator bleibt dennoch grundlegend, denn die Regel prüft lediglich das Vorkommen eines Begriffs, während der Klassifikator alle Begriffe gewichtet und gegeneinander abwägt.

2.6 Evaluationsdesign und Metriken

Alle Verfahren wurden auf demselben Gold-Set von 311 Abbildungen ausgewertet, so dass die Werte unmittelbar vergleichbar sind. Als Hauptkennzahl dient der Macro-F1, also der ungewichtete Mittelwert der klassenweisen F1-Werte. Diese Wahl folgt aus der Datenstruktur. Ein Verfahren, das ausschließlich die häufige Klasse Plot vorhersagt, erreicht bei einer einfachen Trefferquote scheinbar akzeptable Werte, erkennt Diagramm und Photo jedoch überhaupt nicht. Der Macro-F1 gewichtet alle drei Klassen gleich und deckt dieses Verhalten auf. Ergänzend werden Precision und Recall je Klasse sowie die Exact-Match-Quote berichtet, bei der eine Abbildung nur dann als korrekt gilt, wenn alle drei Labelentscheidungen zutreffen.

3 Ergebnisse

3.1 Struktur des annotierten Datensatzes

Vor der Betrachtung der Modellgüte lohnt ein Blick auf die Zusammensetzung der Ground Truth, da sie die Ergebnisse maßgeblich prägt. Die drei Klassen sind deutlich ungleich verteilt. Im Trainingsset tragen 692 der 943 Abbildungen das Label Plot (73,4 Prozent), 410 das Label Diagram (43,5 Prozent) und 206 das Label Photo (21,8 Prozent). Im Gold-Set fällt die Verteilung mit 74,3, 42,4 und 27,7 Prozent sehr ähnlich aus, was für eine repräsentative Aufteilung spricht. Die Anteile summieren sich auf über 100 Prozent, da Mehrfachzuweisungen möglich sind.

Die Multi-Label-Struktur ist dabei erheblich ausgeprägter als zunächst erwartet. Von den 943 Trainingsabbildungen tragen 633 genau ein Label, 255 zwei Labels und 55 alle drei. Der Anteil zusammengesetzter Abbildungen liegt damit bei 32,9 Prozent, im Gold-Set bei 35,0 Prozent. Nahezu jede dritte wissenschaftliche Abbildung erfüllt also mehrere Funktionen gleichzeitig.




Abbildung 1: Label-Kombinationen im Trainingsset (links) und Klassenanteile in Trainings- und Evaluationsset (rechts). Die Anteile summieren sich wegen der Mehrfachzuweisungen auf über 100 Prozent.

Klasse	Training (n = 943)	Anteil	Gold-Set (n = 311)	Anteil
Plot	692	73,4 %	231	74,3 %
Diagram	410	43,5 %	132	42,4 %
Photo	206	21,8 %	86	27,7 %
davon Multi-Label	310	32,9 %	109	35,0 %

Tabelle 1: Klassenverteilung und Anteil zusammengesetzter Abbildungen in der Ground Truth.

Der Befund hat methodische und inhaltliche Konsequenzen. Methodisch bestätigt er die Entscheidung für ein Multi-Label-Verfahren, denn ein Modell mit exklusiver Zuordnung hätte bei einem Drittel der Daten systematisch unvollständige Ergebnisse geliefert. Inhaltlich zeigt er, dass zusammengesetzte Mehrfachtafeln in der biowissenschaftlichen Publikationspraxis die Regel und nicht die Ausnahme sind.

Betrachtet man nicht die Klassen einzeln, sondern die tatsächlich vergebenen Labelkombinationen, tritt die Struktur der Daten noch deutlicher hervor. Von den sieben möglichen Kombinationen entfallen allein 42,3 Prozent des Trainingssets auf reine Plots. Die zweithäufigste Ausprägung ist mit 19,2 Prozent bereits eine Mischform aus Plot und Diagram. Reine Photos sind mit 8,2 Prozent vergleichsweise selten, während Photos in Kombination mit anderen Typen zusammen 13,7 Prozent ausmachen. Photos treten in unseren Daten also überwiegend als Bestandteil zusammengesetzter Tafeln auf und nicht als eigenständige Abbildung. Dieser Umstand erklärt die spätere Erkennungsschwäche dieser Klasse mit, da die Bildunterschrift in solchen Fällen meist mehrere Bildteile gemeinsam beschreibt.

Labelkombination	Training (n = 943)	Anteil	Gold-Set (n = 311)	Anteil
Plot	399	42,3 %	135	43,4 %
Plot + Diagram	181	19,2 %	39	12,5 %
Diagram	157	16,6 %	51	16,4 %

Labelkombination	Training (n = 943)	Anteil	Gold-Set (n = 311)	Anteil
Photo	77	8,2 %	16	5,1 %
Plot + Photo	57	6,0 %	28	9,0 %
Plot + Diagram + Photo	55	5,8 %	29	9,3 %
Diagram + Photo	17	1,8 %	13	4,2 %

Tabelle 2: Verteilung der Labelkombinationen in Trainings- und Evaluationsset.

3.2 Vergleich der Verfahren

Auf dem unabhängigen Gold-Set ergibt sich eine klare Rangfolge. Die Mehrheitsklassen-Baseline erreicht einen Macro-F1 von 0,284, die regelbasierte Schlüsselwortsuche 0,578 und der trainierte Klassifikator 0,700. Der Abstand zwischen den Verfahren beantwortet unmittelbar die zweite Forschungsfrage. Eine literaturgestützte und datengetrieben ergänzte Wortliste erreicht bereits ein beachtliches Niveau, doch das gewichtete Abwägen der logistischen Regression steigert den Macro-F1 um weitere 0,122 Punkte. Noch deutlicher fällt der Unterschied bei der Exact-Match-Quote aus, die von 0,273 auf 0,457 steigt.




Abbildung 2: Macro-F1 der untersuchten Verfahren auf dem Gold-Set (n = 311). Alle Verfahren wurden auf identischer Datengrundlage ausgewertet.

Verfahren	Macro-F1	Micro-F1	Exact-Match
Mehrheitsklasse (Majority)	0,284	–	–
Regelbasierte Suche (Regex)	0,578	0,588	0,273
Klassifikator (TF-IDF + LogReg)	0,700	0,755	0,457

Tabelle 3: Gesamtergebnisse aller Verfahren auf dem Gold-Set.

3.3 Ergebnisse pro Klasse

Der aggregierte Wert verdeckt erhebliche Unterschiede zwischen den Klassen. Plot wird mit einem F1-Wert von 0,869 sehr zuverlässig erkannt, Diagram erreicht 0,662 und Photo lediglich 0,568. Aufschlussreich ist dabei weniger der F1-Wert selbst als das Verhältnis von Precision und Recall. Bei Photo steht einer Precision von 0,677 ein Recall von nur 0,488 gegenüber. Wenn das Modell ein Photo vorhersagt, liegt es meist richtig, es übersieht jedoch über die Hälfte der tatsächlich vorhandenen Fälle.




Abbildung 3: Precision, Recall und F1-Wert des Klassifikators je Klasse auf dem Gold-Set. In Klammern die Anzahl der jeweils vorhandenen Abbildungen.

Klasse	Anzahl	Precision	Recall	F1
Plot	231	0,848	0,892	0,869
Diagram	132	0,618	0,712	0,662
Photo	86	0,677	0,488	0,568
Macro-Mittel	311	0,714	0,697	0,700

Tabelle 4: Klassenweise Ergebnisse des Klassifikators auf dem Gold-Set.

Zwei Faktoren erklären diesen Befund. Zum einen ist Photo mit 86 Fällen die kleinste Klasse, was das Lernen erschwert. Der zweite und gewichtigere Grund liegt in der Sprache selbst. Bildunterschriften von Mikroskopie- oder Gelaufnahmen benennen häufig den biologischen Gegenstand und die Messgröße, ohne die Bildhaftigkeit sprachlich zu markieren. Formulierungen wie „Abundance of enzymes and metabolites“ enthalten keinen Hinweis darauf, dass ein reales Aufnahmebild vorliegt. Hier stößt das textbasierte Vorgehen an eine prinzipielle Grenze.

3.4 Einfluss des Multi-Label-Trainings

Da rund ein Drittel der Abbildungen mehrere Typen trägt, wurde geprüft, welchen Beitrag diese Fälle im Training leisten. Dazu wurde derselbe Klassifikator einmal ausschließlich

auf eindeutig zugeordneten Abbildungen und einmal auf dem vollständigen Trainingsset gelernt und jeweils auf identischen Testdaten ausgewertet. Das Ergebnis ist eindeutig. Der Macro-F1 steigt von 0,615 auf 0,740, die Exact-Match-Quote von 0,531 auf 0,560. Da dieses Zusatzexperiment auf einer eigenen Trainings- und Testaufteilung beruht, liegen seine absoluten Werte leicht über denen der Hauptevaluation in Abschnitt 3.2. Aussagekräftig ist hier allein der Abstand zwischen beiden Varianten, nicht die Höhe der Einzelwerte.

Die Erklärung dafür ist einfach. Ein Modell, dem im Training nie eine Abbildung mit gleichzeitig zwei Typen begegnet ist, kann die entsprechenden sprachlichen Muster nicht lernen und wird sie folglich auch nicht vorhersagen. Die Aufnahme zusammengesetzter Abbildungen in das Training ist damit eine Voraussetzung für die Leistungsfähigkeit des Verfahrens.

3.5 Kombination von Regelwerk und Klassifikator

Es liegt nahe zu vermuten, dass eine Verbindung beider Verfahren die jeweiligen Stärken bündelt. Diese Annahme wurde im Projekt geprüft und nicht nur diskutiert. Untersucht wurden eine disjunktive Variante, bei der ein Label vergeben wird, sobald eines der beiden Verfahren es vorhersagt, sowie eine konjunktive Variante, bei der beide Verfahren übereinstimmen müssen.

Variante	Macro-F1	Micro-F1	Exact-Match
Klassifikator allein	0,700	0,755	0,457
Regex allein	0,578	0,588	0,273
Kombination ODER	0,696	0,735	0,350
Kombination UND	0,570	0,589	0,350

Tabelle 5: Ergebnisse der geprüften Kombinationsvarianten auf dem Gold-Set.

Keine der Kombinationen übertrifft den Klassifikator. Die disjunktive Variante erreicht mit 0,696 zwar einen nahezu identischen Macro-F1, fällt bei der Exact-Match-Quote jedoch deutlich ab, da sie die Fehltreffer der Regel mit übernimmt. Die konjunktive Variante verliert erwartungsgemäß Recall, weil sie nur dort ein Label setzt, wo beide Verfahren übereinstimmen. Aus diesem Grund wird der Klassifikator als alleiniges Verfahren eingesetzt. Diese Entscheidung beruht damit auf einer Messung und nicht auf einer Plausibilitätsannahme.

3.6 Sprachliche Signatur der Abbildungstypen

Da das gewählte Modell linear ist, lassen sich die gelernten Gewichte direkt auslesen. Sie zeigen, welche Begriffe am stärksten für eine Klasse sprechen, und beantworten damit den ersten Teil der dritten Forschungsfrage.

Klasse	Am stärksten gewichtete Begriffe
Plot	mean, values, error bars, curves, axis, line, standard, time
Diagram	schematic, workflow, structure, network, phylogenetic, model, representation
Photo	scale bar, cells, images, brain, cortical, expression, representative

Tabelle 6: Die höchstgewichteten Begriffe je Klasse im trainierten Modell.

Die drei Wortfelder sind inhaltlich klar unterscheidbar und decken sich mit der fachlichen Erwartung. Plot-Captions sprechen die Sprache quantitativer Auswertung und benennen Messwerte, Streuungsmaße und Achsen. Diagram-Captions verwenden Begriffe der Struktur- und Prozessbeschreibung. Photo-Captions greifen auf Aufnahmemodalitäten und biologische Objekte zurück, wobei „scale bar“ als Verweis auf den Maßstabsbalken ein besonders spezifischer Indikator ist. Diese Wortfelder sind der eigentliche Beleg dafür, dass Bildunterschriften den visuellen Typ überhaupt kodieren, denn ohne systematische sprachliche Unterschiede wäre die erzielte Klassifikationsgüte nicht erklärbar.

3.7 Fehleranalyse

Die Fehler des Modells sind nicht zufällig verteilt, sondern folgen erkennbaren Mustern. Die häufigste Verwechslung betrifft Plot und Diagram. Beide Typen teilen sich ein Vokabular der Struktur- und Beziehungsbeschreibung, denn Begriffe wie „network“ oder „structure“ treten sowohl in Netzwerkdiagrammen als auch in datengetriebenen Darstellungen auf. Eine Caption, die mit „Schematic illustration of the setup“ beginnt, zieht das Modell auch dann zu Diagram, wenn die Abbildung im Kern ein Messdiagramm zeigt.

Der zweite Fehlerschwerpunkt liegt bei Photo. In der Gegenrichtung zu den übersehenen Fällen führen geografische oder räumliche Beschreibungen wie „Location map ... highlighted in red“ gelegentlich zu einer fälschlichen Photo-Zuweisung. Beide Muster verweisen auf dieselbe Ursache. Der Klassifikator interpretiert nicht das Bild, sondern dessen sprachliche Beschreibung, und diese ist bei zusammengesetzten Mehrfachtafeln häufig auf den inhaltlichen Befund und nicht auf die Darstellungsform ausgerichtet.

3.8 Anwendung auf einen Gesamtkorpus

Um die Skalierbarkeit des Ansatzes zu demonstrieren, wurde das trainierte Modell auf einen wesentlich größeren Bestand von 43.897 Abbildungen mit auswertbarer Bildunterschrift angewendet. Dieser Datensatz stammt aus dem Bestand einer anderen Projektgruppe und enthält keine PDF-Dateien. Eine Evaluation ist dort folglich nicht möglich, da keine manuell erstellte Ground Truth vorliegt. Die folgenden Werte sind Modellschätzungen und ausdrücklich keine gemessenen Kennzahlen.




Abbildung 4: Vorhergesagte Verteilung der Abbildungstypen über 43.897 Abbildungen des Demonstrationskorpus. Es handelt sich um Modellschätzungen ohne manuelle Validierung.

Der Klassifikator ordnet 83,4 Prozent der Abbildungen dem Typ Plot zu, 38,8 Prozent Diagram und 14,5 Prozent Photo. Rund ein Drittel erhält mehr als ein Label, wobei die Kombination Plot und Diagram mit 9.229 Fällen am häufigsten auftritt. Bei der Interpretation ist Zurückhaltung geboten, da die Verteilung die Fehlertendenzen des Modells übernimmt. Wegen des niedrigen Photo-Recalls ist dieser Anteil vermutlich zu niedrig, der Diagram-Anteil eher zu hoch. Der Wert dieses Schritts liegt daher weniger in den konkreten Prozentzahlen als im Nachweis, dass das Verfahren ohne Bilddaten auf Bestände dieser Größenordnung anwendbar ist.

Aufschlussreicher als die Gesamtverteilung ist die Aufschlüsselung nach Fachrichtung, da sie eine inhaltliche Plausibilitätsprüfung der Vorhersagen erlaubt. Der Korpus verteilt sich auf 26 Fachgebiete, wobei Neuroscience mit 12.227 Abbildungen den größten Anteil stellt. Der Plot-Anteil bewegt sich über alle Gebiete hinweg in einem engen Band zwischen 75 und 93 Prozent, während die beiden übrigen Typen erheblich stärker variieren.

Fachrichtung	Abbildungen	Plot	Diagram	Photo
Neuroscience	12.227	83,4 %	37,6 %	13,4 %
Bioinformatics	4.929	80,6 %	47,3 %	4,6 %
Evolutionary Biology	4.118	85,8 %	31,6 %	3,0 %
Ecology	2.281	87,0 %	23,4 %	1,3 %
Genomics	2.145	87,0 %	36,0 %	8,3 %
Cell Biology	1.901	92,1 %	40,2 %	56,9 %
Biophysics	1.696	75,0 %	48,3 %	11,6 %
Microbiology	1.650	90,1 %	32,3 %	20,7 %
Systems Biology	1.467	84,7 %	48,9 %	8,5 %

Fachrichtung	Abbildungen	Plot	Diagram	Photo
Cancer Biology	1.455	93,3 %	35,3 %	37,5 %

Tabelle 7: Vorhergesagte Typverteilung in den zehn größten Fachrichtungen des Demonstrationskorpus (Multi-Label, Anteile je Zeile über 100 Prozent möglich).

Die Unterschiede folgen erkennbar der fachlichen Erwartung und stützen damit die Annahme, dass das Modell inhaltlich sinnvolle Muster erfasst. In Cell Biology und Cancer Biology, also in mikroskopiegetriebenen Feldern, erreicht der Photo-Anteil 56,9 beziehungsweise 37,5 Prozent, während er in Ecology mit 1,3 Prozent und in Evolutionary Biology mit 3,0 Prozent nahezu verschwindet. Umgekehrt fällt der Diagram-Anteil in methodisch-konzeptionell geprägten Feldern wie Systems Biology (48,9 Prozent), Biophysics (48,3 Prozent) und Bioinformatics (47,3 Prozent) am höchsten aus, also dort, wo Arbeitsabläufe, Modelle und Netzwerke erklärt werden müssen. Diese Trennschärfe zwischen den Fachkulturen ist ein indirektes Qualitätssignal, denn ein Modell, das lediglich die häufigste Klasse reproduzieren würde, könnte solche systematischen Unterschiede nicht erzeugen. Sie ersetzt jedoch keine Evaluation, da eine manuelle Referenz für diesen Bestand fehlt.

4 Diskussion und Fazit

4.1 Beantwortung der Forschungsfragen

Die erste Forschungsfrage lässt sich differenziert bejahen. Bildunterschriften kodieren den visuellen Typ einer Abbildung in erheblichem Umfang, denn ein Macro-F1 von 0,700 liegt weit über dem Nullpunkt von 0,284 und belegt, dass substantielle Information im Text vorhanden ist. Die Einschränkung liegt in der ungleichen Verteilung dieser Information über die Klassen. Was quantitativ dargestellt wird, wird sprachlich präzise benannt, was fotografisch dokumentiert wird, dagegen häufig nicht.

Die zweite Frage beantwortet der Vergleich der Verfahren. Der trainierte Klassifikator übertrifft die regelbasierte Suche deutlich, besonders ausgeprägt bei der strengen Exact-Match-Quote. Der Mehrwert liegt erkennbar im gewichteten Abwägen. Während die Regel jedes Vorkommen gleich behandelt, kann der Klassifikator schwache Indizien summieren und widersprüchliche Hinweise gegeneinander verrechnen. Dass zusätzlich keine Kombination beider Verfahren eine Verbesserung erbringt, stützt diesen Befund.

Die dritte Frage beantworten die klassenweise Auswertung und die sprachliche Signatur gemeinsam. Die drei Abbildungstypen verfügen über klar unterscheidbare Wortfelder, doch ihre Unterscheidbarkeit ist asymmetrisch. Die Grenze des Verfahrens liegt dort, wo eine Caption den wissenschaftlichen Befund beschreibt, ohne die Darstellungsform zu erwähnen. Dieses Muster tritt bei Photos systematisch häufiger auf als bei Plots.

4.2 Vergleich mit dem bildbasierten Vorgehen

Der Vergleich mit Lee et al. (2016) verlangt zunächst eine methodische Vorbemerkung, da ein unmittelbares Gegenüberstellen der Kennzahlen irreführend wäre. Die dort

berichteten rund 91 Prozent beziehen sich auf eine Accuracy bei exklusiver Zuordnung zu fünf Kategorien, gemessen auf einem Testset aus zuvor zerlegten Einzelabbildungen. Unser Wert von 0,700 ist ein Macro-F1 über drei Klassen in einem Multi-Label-Setting auf ungeteilten Abbildungen, bei dem eine Mehrfachtafel nur dann vollständig korrekt ist, wenn alle zutreffenden Typen erkannt werden. Die hier gestellte Aufgabe ist damit in mehrfacher Hinsicht schwieriger, und die Zahlen sind nicht direkt vergleichbar.

Aussagekräftig ist dagegen der qualitative Vergleich. Das bildbasierte Verfahren ist in der Erkennungsleistung überlegen, weil es auf die Information zugreift, die tatsächlich klassifiziert werden soll. Ob eine Fläche aus Achsen und Datenpunkten oder aus fotografischen Grauwerten besteht, ist im Pixelbild unmittelbar erkennbar, in der Bildunterschrift dagegen nur mittelbar und mitunter gar nicht. Am deutlichsten zeigt sich das bei der Klasse Photo, die mit einem Recall von 0,488 unseren schwächsten Wert erreicht, während Lee et al. fotografische Aufnahmen anhand von Textur- und Farbmerkmalen gut abgrenzen können. Der in Abschnitt 3.3 beschriebene Grund dafür ist kein Mangel des Modells, sondern eine Eigenschaft des Gegenstandsbereichs.

Der textbasierte Ansatz besitzt gleichwohl Vorteile jenseits der reinen Erkennungsleistung. Er benötigt keine Bilddateien und ist damit überall dort einsetzbar, wo lediglich strukturierte Metadaten vorliegen. Die Klassifikation von rund 44.000 Abbildungen war ohne Bildvorverarbeitung und ohne spezialisierte Hardware in wenigen Minuten abgeschlossen. Zudem ist das Modell interpretierbar, denn die Wortgewichte aus Abschnitt 3.6 erlauben eine inhaltliche Auswertung der Frage, wie über Abbildungen gesprochen wird. Beide Ansätze greifen damit auf komplementäre Signale zu.

An einem inhaltlichen Punkt stimmen beide Arbeiten schließlich überein. Lee et al. ermitteln über ihre Bildzerlegung, dass rund 35 Prozent der Abbildungen aus mehreren Teilabbildungen bestehen, und unsere manuelle, rein visuell vorgenommene Annotation kommt mit 32,9 beziehungsweise 35,0 Prozent praktisch auf denselben Wert. Zwei methodisch unabhängige Wege führen hier zum gleichen Befund. Auch die Rangfolge der Typen stimmt überein, denn in beiden Arbeiten ist Plot der häufigste Typ. Die absoluten Anteile weichen jedoch erheblich ab. Lee et al. weisen 35,0 Prozent Plot und 22,7 Prozent Photo aus, unser Korpuslauf 83,4 beziehungsweise 14,5 Prozent. Ursächlich sind die Multi-Label-Zählung ohne Zerlegung, das abweichende Fachprofil des bioRxiv-Bestands und das systematische Untererkennen von Photos durch unser Modell.

Die folgende Übersicht stellt beide Vorgehensweisen entlang der wesentlichen Merkmale gegenüber. Sie macht sichtbar, dass es sich weniger um konkurrierende Lösungen desselben Problems handelt als um Verfahren mit unterschiedlichen Voraussetzungen und Einsatzbereichen.

Merkmal	Lee et al. (bildbasiert)	Diese Arbeit (caption-basiert)
Eingabe	Pixeldaten der Abbildung	Text der Bildunterschrift
Korpusgröße	rund 4,8 Mio. Abbildungen (PubMed Central)	1.254 annotierte Abbildungen; Anwendung auf 43.897

Merkmal	Lee et al. (bildbasiert)	Diese Arbeit (caption-basiert)
Kategorien	5 (inkl. Equation und Table)	3 (Plot, Diagram, Photo)
Zuordnung	exklusiv, nach Zerlegung zusammengesetzter Abbildungen	Multi-Label ohne Zerlegung
Verfahren	Bildmerkmale und Support Vector Machine	TF-IDF und logistische Regression (One-vs-Rest)
Berichtete Güte	rund 91 % Accuracy (5 Klassen, exklusiv)	Macro-F1 0,700; Exact-Match 0,457 (3 Klassen, Multi-Label)
Zusammengesetzte Abbildungen	rund 35 % (per Bildzerlegung ermittelt)	32,9 % (Training) bzw. 35,0 % (Gold-Set), manuell ermittelt
Voraussetzungen	Bilddateien und Bildvorverarbeitung	nur strukturierte Metadaten, keine Bilddateien
Rechenaufwand	hoch, für Millionenbestände auf Cluster ausgelegt	gering, rund 44.000 Abbildungen in Minuten auf einem Arbeitsplatzrechner
Interpretierbarkeit	Bildmerkmale nur eingeschränkt deutbar	Wortgewichte direkt auslesbar und inhaltlich auswertbar

Tabelle 8: Gegenüberstellung des bildbasierten Vorgehens nach Lee et al. (2016) und des in dieser Arbeit verfolgten caption-basierten Ansatzes.

4.3 Kritische Reflexion

Mehrere Einschränkungen sind bei der Bewertung der Ergebnisse zu berücksichtigen. Die grundlegendste betrifft den Gegenstand der Messung. Erhoben wird, was die Bildunterschrift über den Abbildungstyp verrät, nicht der Typ selbst. Das ist die bewusst gewählte Forschungsfrage, macht das Verfahren jedoch zu keinem Ersatz für bildbasierte Klassifikation, sondern zu einer Ergänzung für Anwendungsfälle ohne Bildzugang.

Zur Annotation ist einschränkend anzumerken, dass zwar im Team und nach gemeinsam abgestimmten Kriterien gearbeitet wurde, ein systematisch gemessenes Übereinstimmungsmaß zwischen den Annotierenden jedoch aussteht. Ein solches Maß, etwa Cohens oder Fleiss' Kappa auf einer überlappend annotierten Teilstichprobe, wäre nachträglich mit vertretbarem Aufwand zu erheben und würde die Belastbarkeit der Ground Truth zusätzlich absichern. Da die Grenzziehung zwischen Plot und Diagram in Einzelfällen Ermessensspielraum lässt, ist nicht auszuschließen, dass ein Teil der beobachteten Modellfehler auf Uneinheitlichkeit in den Referenzlabels zurückgeht.

Der Umfang der Datenbasis begrenzt die statistische Belastbarkeit insbesondere für die kleinste Klasse. Mit 86 Photo-Fällen im Gold-Set reagieren die dortigen Kennzahlen empfindlich auf einzelne Fehlklassifikationen. Die Ergebnisse des Korpuslaufs sind schließlich, wie in Abschnitt 3.8 ausgeführt, Modellschätzungen, die die Fehlertendenzen des Klassifikators übernehmen und nicht als gemessene Verteilung gelesen werden dürfen. Die Aussagen gelten zudem für biowissenschaftliche Preprints, eine Übertragbarkeit auf andere Disziplinen mit abweichenden Publikationskonventionen ist nicht geprüft.

Rückblickend hätten drei Entscheidungen die Aussagekraft der Arbeit erhöht. Erstens wäre eine überlappend annotierte Teilstichprobe von etwa hundert Abbildungen bereits zu Beginn sinnvoll gewesen, denn sie hätte mit geringem Mehraufwand ein belastbares Übereinstimmungsmaß geliefert und die strittigen Grenzfälle zwischen Plot und Diagramm früh sichtbar gemacht. Zweitens hätte ein eigenes Validierungsset erlaubt, die Entscheidungsschwelle klassenweise anzupassen, ohne dafür das Gold-Set heranzuziehen. Gerade für Photo wäre eine Absenkung zugunsten des Recalls naheliegend gewesen. Drittens hätte ein auf unseren eigenen Daten ausgeführtes bildbasiertes Vergleichsverfahren den Vergleich in Abschnitt 4.2 von einer literaturgestützten Einordnung zu einer echten Messung gemacht. Ein solcher Ansatz wurde im Projektverlauf erprobt, aber verworfen, weil eine maschinelle Vorbelegung die Unabhängigkeit der manuellen Annotation gefährdet hätte. Nach abgeschlossener Annotation wäre er unproblematisch gewesen.

4.4 Ausblick

Über die in Abschnitt 4.3 genannten Punkte hinaus ergeben sich zwei weiterführende Perspektiven. Die naheliegendste ist eine Verbindung beider Informationsquellen, denn ein Verfahren, das Bild- und Textmerkmale gemeinsam verarbeitet, könnte die komplementären Signale bündeln, sofern Bilddaten verfügbar sind. Darüber hinaus ließe sich der Ansatz auf weitere Fachgebiete übertragen, um zu prüfen, ob die identifizierten sprachlichen Signaturen disziplinspezifisch oder allgemeingültig sind. Die in Abschnitt 3.8 sichtbaren Unterschiede zwischen den Fachrichtungen legen nahe, dass hier weitere Struktur zu finden ist.

Zusammenfassend zeigt die Arbeit, dass Bildunterschriften eine tragfähige, wenn auch nicht gleichwertige Alternative zur bildbasierten Klassifikation darstellen. Der erreichte Macro-F1 von 0,700 liegt deutlich über allen Vergleichsmaßstäben, die klassenweise Analyse macht die Grenzen des Verfahrens transparent, und die sprachlichen Signaturen der drei Abbildungstypen eröffnen einen eigenständigen inhaltlichen Zugang zu der Frage, wie in der Wissenschaft über Abbildungen gesprochen wird.

5 Reproduzierbarkeit und Quellcode

Sämtlicher Quellcode sowie die Ergebnisdateien sind öffentlich zugänglich unter:

https://github.com/Sedat-P/A_Team_dis22-caption-classification

Das Repository enthält die vollständige Verarbeitungskette, also das Annotationswerkzeug, die preprint-reine Datenaufteilung, die Herleitung der regelbasierten Wortlisten, die Hauptevaluation einschließlich Fehleranalyse, die Zusatzexperimente zu Multi-Label-Training und Verfahrenskombination sowie die Anwendung auf den Gesamtkorpus. Eine Anleitung zur Reproduktion der berichteten Kennzahlen, die Abhängigkeiten und eine Beschreibung des erwarteten Datenformats finden sich in der README-Datei. Ergänzend dokumentiert ein eigenes Verzeichnis die im Projektverlauf erprobten, aber verworfenen Ansätze, um den Entscheidungsweg nachvollziehbar zu machen.

Literaturverzeichnis

- Lee, P., West, J. D., & Howe, B. (2016). Viziometrics: Analyzing Visual Information in the Scientific Literature. *IEEE Transactions on Big Data*, 4(1), 117–129. <https://faculty.washington.edu/billhowe/publications/pdfs/lee2016viziometrics.pdf>
- Lee, P., West, J. D., & Howe, B. (2016). VizioMetrix: A Platform for Analyzing the Visual Information in Big Scholarly Data. *Proceedings of the 25th International Conference Companion on World Wide Web (BigScholar Workshop)*.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Datalab, University of Washington Information School. Viziometrics, Projektseite. <https://datalab.ischool.uw.edu/projects/viziometrics> (abgerufen im August 2026).

Abbildungsverzeichnis

Abbildung 1: Label-Kombinationen im Trainingsset (links) und Klassenanteile in Trainings- und Evaluationsset (rechts). Die Anteile summieren sich wegen der Mehrfachzuweisungen auf über 100 Prozent.	6
Abbildung 2: Macro-F1 der untersuchten Verfahren auf dem Gold-Set ($n = 311$). Alle Verfahren wurden auf identischer Datengrundlage ausgewertet.	7
Abbildung 3: Precision, Recall und F1-Wert des Klassifikators je Klasse auf dem Gold-Set. In Klammern die Anzahl der jeweils vorhandenen Abbildungen.	8
Abbildung 4: Vorhergesagte Verteilung der Abbildungstypen über 43.897 Abbildungen des Demonstrationskorpus. Es handelt sich um Modellschätzungen ohne manuelle Validierung.	11

Tabellenverzeichnis

Tabelle 1: Klassenverteilung und Anteil zusammengesetzter Abbildungen in der Ground Truth.	6
Tabelle 2: Verteilung der Labelkombinationen in Trainings- und Evaluationsset.....	7
Tabelle 3: Gesamtergebnisse aller Verfahren auf dem Gold-Set.	7
Tabelle 4: Klassenweise Ergebnisse des Klassifikators auf dem Gold-Set.	8
Tabelle 5: Ergebnisse der geprüften Kombinationsvarianten auf dem Gold-Set.	9
Tabelle 6: Die höchstgewichteten Begriffe je Klasse im trainierten Modell.....	10
Tabelle 7: Vorhergesagte Typverteilung in den zehn größten Fachrichtungen des Demonstrationskorpus (Multi-Label, Anteile je Zeile über 100 Prozent möglich).	12
Tabelle 8: Gegenüberstellung des bildbasierten Vorgehens nach Lee et al. (2016) und des in dieser Arbeit verfolgten caption-basierten Ansatzes.	14
Tabelle 6: Beitragsmatrix der Projektgruppe A-Team.	19

Beitragsmatrix

Die folgende Übersicht dokumentiert die Aufteilung der Projekt- und Berichtsarbeit. Die manuelle Annotation sowie die Abstimmung der Annotationskriterien und der Grenzfälle erfolgten gemeinsam im Team.

Aufgabenbereich	Ismail Salkovic	Talha Arslan	Necip Sedat Palaoglu
Themenfindung und Forschungsfragen	beteiligt	beteiligt	beteiligt
Literaturrecherche und Stand der Forschung	beteiligt	beteiligt	beteiligt
Manuelle Annotation der Abbildungen	beteiligt	beteiligt	beteiligt
Annotationswerkzeug und Datenaufbereitung	beteiligt	beteiligt	unterstützend
Implementierung des Klassifikators	beteiligt	unterstützend	beteiligt
Regelbasierte Baseline und Evaluation	unterstützend	beteiligt	beteiligt
Korpusanwendung und Visualisierungen	beteiligt	beteiligt	unterstützend
Auswertung und Interpretation der Ergebnisse	beteiligt	unterstützend	beteiligt
Präsentation	beteiligt	beteiligt	beteiligt
Erstellung des Berichts	beteiligt	beteiligt	beteiligt
Repository und Dokumentation	unterstützend	beteiligt	beteiligt

Tabelle 9: Beitragsmatrix der Projektgruppe A-Team.