

Die visuelle Sprache wissenschaftlicher Preprints

Caption-basierte Klassifikation von Abbildungen auf bioRxiv

A-Team Ismail Salkovic · Necip Sedat Palaoglu · Talha Arslan

Projektmodul DIS22 · TH Köln · 24. Juni 2026

Betreuung: Prof. Dr. Philipp Schaer · Fabian Haak

Überblick

1 Problem & Stand der Forschung

Warum Abbildungen, warum schwierig, was gibt es bereits

2 Methoden & Daten

Datengrundlage, Annotation, unser Classifier, Baselines, Evaluationsaufbau

3 Ergebnisse, Evaluation & kritische Betrachtung

Leistung, Muster, Korpus-Verteilung, Grenzen

01 Problem & Stand der Forschung

Warum Abbildungen?

- Abbildungen sind zentrale Träger der wissenschaftlichen Argumentation.
- Typ und Qualität visueller Information korrelieren mit dem wissenschaftlichen Impact (Lee et al., 2016).
- Verschiedene Disziplinen haben unterschiedliche visuelle Standards für Evidenz.
- Eine großflächige Analyse macht diese Unterschiede zwischen Fachrichtungen / Themen sichtbar und messbar.

Hauptforschungsfrage

**Lässt sich der Typ einer
Abbildung allein aus ihrer
Bildunterschrift
bestimmen?**

*Und wie gut lässt sich der Abbildungstyp
anhand der Bildunterschrift automatisch
labeln?*

Stand der Forschung: Viziometrics

- Lee et al. (2016): „Viziometrics – Analyzing Visual Information in the Scientific Literature.”
- Klassifiziert ~4,8 Mio. Abbildungen aus dem PubMed-Korpus in sechs Typen.
- Ansatz ist bildbasiert: gelernt wird direkt aus den Pixeln der Abbildung.
- Wir übernehmen das Kategoriensystem, untersuchen aber einen anderen Weg.

- **Plot** bar / scatter / line charts
- **Diagram** schematics, workflows
- **Photo** microscopy, imaging
- **Equation** ausgeschlossen
- **Table** ausgeschlossen

Equation & Table: andere Struktur, eigene Verfahren → bewusst ausgeklammert.

Label: Plot

- Datengetriebene Visualisierung quantitativer Messwerte oder Ergebnisse
- Stellt Zahlen und Trends grafisch dar
- Beispiele:
Balkendiagramm,
Liniendiagramm,
Streudiagramm, Boxplot,
Histogramm, Heatmap
- Zweck: Daten sichtbar und vergleichbar machen




Figure S12: **Sequence-level biophysical properties** measured for sequences from the site-independent baseline (yellow, $n=4,000$) against the mRNA-display test sequences (blue, $n=3,717$).

Label: Diagram

- Schematische oder konzeptuelle Darstellung von Ideen, Strukturen oder Abläufen
- Erklärt Zusammenhänge statt Rohdaten zu zeigen
- Beispiele: Flussdiagramm, Workflow, Pipeline-Übersicht, Modellskizze, Signalweg
- Zweck: Prozesse und Mechanismen verständlich machen




Figure S13: **Phylogenetic tree of (A) catalytic domain sequences and (B) entire MMP sequences.** Solid line: GPI-anchored MMPs; broken line: trans-membrane MMPs; line-dotted: gelatinases; dotted: non furin regulated MMPs. Modified from Andreini et al. (53).

Label: Photo

- Aufgenommene, reale Bilder eines konkreten Objekts oder Präparats
- Beispiele: Mikroskopie- und Fluoreszenzaufnahmen, Histologie, Gel- und Blot-Bilder, Röntgen-/MRT-Scans, Fotografien von Proben oder Versuchsaufbauten
- Zweck: Tatsächlich beobachtete visuelle Evidenz zeigen




Figure S3. Deletion of the ATG5 interacting region of TECPR1 prevents ATG5 recruitment to lysosomes in response to damage. Representative live-cell fluorescent images of HeLa WT cells co-transfected with EGFP-TECPR1 and mCherry-ATG5 and treated with 1 mM LLOMe for 15 minutes. Scale bar = 20 μ M.

Multi-label: Photo, Plot und Diagramm

- Eine Abbildung kann mehreren Klassen gleichzeitig zugeordnet werden
- Relevant bei Figuren mit mehreren Panels unterschiedlicher Typen
- Jede zutreffende Klasse wird vergeben
- Beispiel: Panel (a) = Diagramm, Panel (b) = Plot
- Zweck: Komplexe Abbildungen vollständig und korrekt beschreiben




Figure 6. CyMA modulate tumor microenvironment. (a) Schematic illustration showing the inhibition of cancer associated fibroblasts (CAFs), senescent tumor cells (STCs), and selective inhibition of M2 tumor associated macrophages (TAMs) but not M1 TAM, as well as the suppression of cytokine secretion (TGF-β1 and VEGF). (b) Cell viability of CAFs treated with

Bildbasiert vs. textbasiert

Bildbasiert (Stand der Forschung)

- Klassifikation aus dem Bild selbst
- Braucht die Bilddateien (PDFs)
- Rechenintensiv im großen Maßstab

Caption-basiert (unser Ansatz)

- Klassifikation aus dem Unterschriften-Text
- Nur die JSON-Metadaten nötig, keine Bilder
- Schlank und auf ganze Korpora skalierbar

Unsere Frage: Reicht der Text der Caption, um den visuellen Typ zuverlässig zu erkennen?

02 Methoden & Daten

Datengrundlage

Quelle — Sample-Datensatz aus bioRxiv-Preprints (JSON), den alle Gruppen erhalten haben.

Pro Abbildung — Bildunterschrift (Caption), Position im PDF und Metadaten wie die Fachrichtung.

Zieltypen — Plot, Diagram, Photo. Equation und Table sind ausgeschlossen (andere Struktur).

Multi-Panel — Viele Abbildungen vereinen mehrere Typen in einer einzigen Tafel.

Ein Abbildungs-Eintrag im JSON

<code>caption</code>	Bildunterschrift (Text)
<code>pos_page</code> / <code>bbox</code>	Position & Koordinaten im PDF
<code>metadata</code>	Fachrichtung, DOI

4.019

Abbildungen im Sample-Datensatz

1.921

davon nur mit Label-Caption (kein Text)

3

Zieltypen: Plot · Diagram · Photo

Annotation

- 1000 Abbildungen für Training. 300 Abbildungen für Evaluation
- Strikte preprint-basierte Datentrennung: Keine Überschneidung von Preprints zwischen Trainings- und Evaluationsset, um Data Leakage zu verhindern.
- Python-basiertes Annotationstool mit einer Tkinter Interface
- Automatisiertes PDF-Mapping: Nutzt JSON-Koordinaten, um Abbildungen live und passgenau aus der Original-PDF auszuschneiden und anzuzeigen.
- Effiziente Tastatur-Steuerung: Reine „Keyboard-only“-Bedienung über Hotkeys (z. B. 1 = Plot, 2 = Diagramm, 3 = Foto, 4 = Multilabel) für einen schnellen Workflow.
- Manuelle Annotation erfolgt nur anhand der Bilder. Nicht über Caption

A-Team Annotation

[1/995] annotation_id 6 (10.1101_2025.08.01.668053.json) ✓ bereits: Plot
Maschinen-Label: —

bioRxiv preprint doi: <https://doi.org/10.1101/2025.08.01.668053>; this version posted August 1, 2025. The copyright holder for this preprint (which was not certified by peer review) is the author/funder, who has granted bioRxiv a license to display the preprint in perpetuity. It is made available under aCC-BY-NC 4.0 International license.

Fig. 5 | Growth in SimUrine.v2 and hemin supplemented versions. Cultures of *E. coli* (UBM3190) (A) and *S. anginosus* (UMB8616) (B) in SimUrine.v2 (solid lines) and SimUrine.v2 supplemented with hemin 1X (dotted lines) and hemin 10X (dashed lines). Optical density at 600 nm (OD₆₀₀) is shown on the y-axes; time (hours) on the x-axes. Lines represent mean values and shading standard error of the mean.

SimUrine.v4 represented a major improvement of SimUrine formulation. We incorporated amino acids within urine-relevant concentration ranges (Schmied et al., 2021), changed the order of hemin and uric acid supplementation, and introduced both HEPES and Tween80. We used this formulation to test if bacteria could grow with cysteine or its dimer, cystine. For *E. coli* (UBM3190) and *K. pneumoniae* (UBM9987), SimUrine.v4 resulted in vastly improved OD₆₀₀ (compare Fig.6A and Fig.6B to Fig.5A and Fig.5B) and resulted in substantial growth of *E. faecalis* and *C. riegelii* (Fig.6C and Fig.6D). In all cases, cysteine performed better than cystine.


[GANZE SEITE] Figure: None (Seite 16)

Fig. 5 | Growth in SimUrine.v2 and hemin supplemented versions. Cultures of *E. coli* (UBM3190) (A) and *S. anginosus* (UMB8616) (B) in SimUrine.v2 (solid lines) and SimUrine.v2 supplemented with hemin 1X (dotted lines) and hemin 10X (dashed lines). Optical density at 600 nm (OD₆₀₀) is shown on the y-axes; time (hours) on the x-axes. Lines represent mean values and shading standard error of the mean.

[1] Plot [2] Diagram [3] Photo [4] Multilabel [5] Skip [6] Review [9] Speichern&Ende ([f] ganze Seite [b/-] zurück)

MULTILABEL: [1] Plot+Diagram [2] Plot+Photo [3] Diagram+Photo [4] Plot+Diagram+Photo [Esc] zurück

Der Classifier



- Schritt 1 – Aus Text werden Zahlen (TF-IDF): seltene, typische Begriffe zählen stark, Allerwelts-Wörter kaum.
- Schritt 2 – Drei Modelle, eines pro Typ, lernen aus den annotierten Beispielen die typischen Wörter ihrer Klasse.
- Schritt 3 – Jedes Modell entscheidet Ja oder Nein; zusammen ergibt das die Klassifikation, auch mit mehreren Typen gleichzeitig (Multi-Label).

Vergleichsmaßstäbe (Baselines)

Majority

Rät immer die häufigste Klasse (Plot). Lernt nichts – der unterste Maßstab.

Regex A

Einfache Keyword-Suche: kommt ein Schlüsselwort der Klasse in der Caption vor, wird das Label gesetzt. Begriffe aus den Kategorie-Definitionen von Lee et al. plus datengetrieben aus train_split (TF-IDF) abgeleitet – also belegt, nicht frei erfunden.

Classifier


TF-IDF + Logistic Regression, unser gelernter Ansatz.

Evaluationsaufbau

- Gold-Set – Wir bewerten auf den 311 unabhängigen Abbildungen aus der Annotation, die das Modell beim Training nie gesehen hat.
- Fairer Vergleich – Majority, Regex, Classifier und Regex + Classifier laufen auf demselben Evaluations set. Nur so ist der Vergleich aussagekräftig.
- Metrik Macro-F1 – gewichtet alle drei Klassen gleich, damit die häufige Plot-Klasse das Ergebnis nicht schöntr. Zusätzlich Precision und Recall pro Klasse.
- Robustheit – die Bewertung wiederholen wir über mehrere paper-getrennte Aufteilungen; die Leistung bleibt stabil bei rund 0,70.

03 Ergebnisse, Evaluation & kritische Betrachtung

Leistung: Macro-F1 auf dem Gold-Set



Klare Treppe

Auf dem Gold-Set erreicht der Classifier einen Macro-F1 von **0,70** und schlägt damit sowohl die Regex A+ Classifier Kombi ODER (**0,69**), Keyword-Baseline Regex A (**0,58**) als auch das triviale Majority-Raten (**0,28**) deutlich.

In zusätzlichen paper-getrennten Wiederholungen bleibt die Leistung stabil bei ca. **0,70 ± 0,02**.

Gold-Set: 311 Abbildungen – für Majority, Regex A, Regex A + Classifier Kombi ODER und Classifier identisch angewendet.

Ergebnisse pro Klasse


Klasse	Support	Precision	Recall	F1
Plot	231	0,85	0,89	0,87
Diagram	132	0,62	0,71	0,66
Photo	86	0,68	0,49	0,57

- Plot wird am zuverlässigsten erkannt. Diagram und Photo sind schwieriger; besonders Photo wird häufig übersehen (Recall 0,49).

Warum Macro-F1?

- Die Klassen sind ungleich verteilt: Plot kommt am häufigsten vor.
- Ein Modell, das immer „Plot“ vorhersagt, wirkt bei einfacher Trefferquote besser, erkennt aber Diagram und Photo gar nicht.
- Macro-F1 bewertet alle drei Klassen gleich stark und verhindert, dass Plot das Ergebnis dominiert.

Lohnt sich Multi-Label-Training?



Ergebnis

Werden zusammengesetzte Abbildungen ins Training aufgenommen, steigt der Macro-F1 von **0,61** auf **0,74**.

Multi-Label-Beispiele helfen dem Modell, kombinierte Figuren wie **Plot + Diagram** besser zu erkennen.

Gleiche Testdaten, gleicher Classifier – nur Trainingsdaten unterschiedlich.

Abbildungstypen haben erkennbare Caption-Signale



Plot

mean · values · error bars · curves · axis · line · standard · time



Diagram

schematic · workflow · structure · network · phylogenetic · model · representation



Photo

scale bar · cells · images · brain · cortical · expression · representative

Top-gewichtete Begriffe pro Klasse im Modell – sie zeigen, welche Caption-Hinweise besonders stark für ein Label sprechen.

Wo das Modell scheitert

- Plot und Diagram werden am häufigsten verwechselt, da sie teils ähnliches Vokabular nutzen, z. B. „network“ oder „structure“.
- Photo hat den niedrigsten Recall: Viele echte Photos werden nicht erkannt (Recall 0,49).
- Viele Fehler entstehen durch überlappende Sprache in den Captions, besonders bei Multi-Panel-Figuren.

Typische Fehlbeispiele


Diagram → Vorhersage: Plot „Task setup and behavioural results ...“

Plot → Vorhersage: Diagram „...Schematic illustration of the setup...“

Photo übersehen „Abundance of enzymes and metabolites ...“

fälschlich Photo „Location map...highlighted in red“

Anwendung auf ein Testdatensatz



Verteilung über 43.897 klassifizierte Abbildungen aus der Sample-Data
(Multi-Label: Anteile summieren sich nicht auf 100 %)

● **Plot: 83 %**

● **Diagram: 39 %**

● **Photo: 15 %**

Rund ein Drittel sind zusammengesetzte Multi-Panel-Abbildungen; häufigste Kombination: Plot + Diagram.

Hinweis: Dies ist eine Modellschätzung, keine manuelle Evaluation. Aufgrund der Fehlertendenzen ist Photo wahrscheinlich eher unterschätzt; Diagram kann überschätzt sein.

Grenzen unserer Arbeit

Caption als Stellvertreter — Wir klassifizieren, was die Caption über den Abbildungstyp verrät, nicht das Bild selbst.
Bewusste Forschungsfrage, kein Ersatz für bildbasierte Verfahren.

Annotation — Hand-Labels durch unser Teams; ein systematischer gemessenes Inter-Annotator-Agreement, z. B. Cohen's Kappa, steht noch aus.

Korpus-Verteilung — Die vorhergesagt Verteilung übernimmt die Fehlertendenzen des Classifiers; besonders Photo ist wegen des niedrigen Recalls unsicher.

Reichweite — Eigener Sample-Datensatz (Preprints mit PDFs); Aussagen gelten für diesen Ausschnitt.

Diese Grenzen benennen wir offen – sie ordnen unsere Zahlen ehrlich ein.

Was lernen wir daraus

Plots dominieren → wissenschaftliche Argumentation läuft stark über quantitative Evidenz.

Diagramme ergänzen Plots → sie erklären Workflows, Modelle und Zusammenhänge.

Photos sind seltener und schwerer erkennbar → reale Bildaufnahmen werden in Captions nicht immer eindeutig markiert.

Viele Figures sind zusammengesetzt → Abbildungen erfüllen oft mehrere Funktionen gleichzeitig, z. B. erklären + belegen

Captions beschreiben nicht nur den Inhalt einer Abbildung, sondern geben Hinweise auf ihre wissenschaftliche Funktion.

Fazit

- Unser caption-basierter Classifier erreicht einen Macro-F1 von 0,70 – deutlich über Keyword- und Trivial-Baseline.
- Jeder Abbildungstyp hat eine erkennbare sprachliche Signatur.
- Anwendung auf **43.897 Abbildungen**: Plots dominieren; rund ein Drittel ist zusammengesetzt.
- Ausblick: Inter-Annotator-Agreement, bessere Photo-Erkennung, Übertrag auf weitere Disziplinen.

Vielen Dank — Fragen?